

RASD 360 — Comment on calcule tout

Fiche des formules · annexe de la présentation · montants en dinars (DT) · données fictives 2023–2025

À dire au jury (30 secondes)

« On ne compare pas bêtement importations et chiffre d'affaires. D'abord on corrige les écarts honnêtes (stock, machines, exportations). Ensuite on croise des sources que l'entreprise ne contrôle pas, avec 14 règles chiffrées. Enfin l'IA classe : priorité = probabilité de réussite × montant en jeu. L'agent décide. »

- « C'est du machine learning ? » Les règles sont des calculs fixes et vérifiables. Le ML sert seulement à classer (LightGBM) et à repérer l'inhabituel (Isolation Forest). SHAP explique chaque score.
- « Et si l'entreprise est honnête ? » Montrer Cap Bon Distribution : même écart brut que Sahel Électro, mais le stock l'explique. Elle est verte.

1. Les données

- 5 sources par entreprise : douane (importations, exportations), impôts (TVA mensuelle, déclaration annuelle), TEJ (paiements attestés par les clients), El Fatoora (factures émises), banque (encaissements).
- Taux de TVA 19 % et taux d'IS 15 % : paramètres « à vérifier » (codes de la TVA et de l'IS non indexés).
- Prix de référence = médiane, 10^e et 90^e centiles du prix unitaire CIF (valeur CIF ÷ quantité), par couple (code SH, pays d'origine), au moins 5 observations.

2. Neutraliser les explications honnêtes

Coût des ventes net = importations à revendre + achats locaux – variation de stock

- Importations à revendre = Σ (valeur CIF + droits), mise à la consommation, hors machines (annexe du décret 2017-419) et hors admission temporaire.
- Achats locaux = $\max(0 ; \text{achats déclarés} - \text{importations à revendre} - \text{admission temporaire})$.
- Variation de stock = stock final – stock initial.
- CA = Σ déclarations mensuelles de TVA (ventes locales + exportations) ; CA TTC = ventes locales × 1,19 + exportations.

Marge implicite = CA ÷ coût des ventes net – 1

- Sur 36 mois : Σ CA sur 3 ans ÷ Σ coûts sur 3 ans – 1 (neutralise le décalage de période).
- Comparaison au secteur (code d'activité NAT 2009, simple table de correspondance, pas de ML) : marge médiane de référence du secteur et 5^e centile des marges du secteur.
- Marge non calculée pour les services, si l'admission temporaire dépasse 20 % des achats, ou si le coût est inférieur à 5 % du CA ou à 10 000 DT.

3. Les 14 règles

■ Niveau A — contradiction directe avec des tiers (quasi-preuve)

Règle	Se déclenche si	Montant en jeu
A1	TEJ ÷ CA > 1,05 et TEJ – CA > 5 000 DT	(TEJ – CA) × 19 %
A2	factures El Fatoora ÷ CA > 1,05 et écart > 5 000 DT	(factures – CA) × 19 %
A3	TVA déduite à l'import – TVA payée en douane > 2 % de la TVA payée et > 5 000 DT (TVA payée = maximum entre janvier–décembre et décembre précédent–novembre : 1 mois de décalage toléré)	TVA déduite – TVA payée
A4	exportations déclarées ÷ exportations en douane > 1,10 et écart > 10 000 DT (vente de biens)	écart × 19 %
A5	au moins 3 mois sans déclaration de TVA alors qu'il y a > 10 000 DT d'encaissements ou une importation	encaissements ÷ 1,2 × 19/119

■ Niveau B — anomalie économique forte, après neutralisation

Règle	Se déclenche si	Montant en jeu
B1	marge < max(5 ^e centile du secteur ; 0), au moins 2 ans sur 3	(coût × (1 + marge médiane du secteur) – CA) × 19 %
B2	prix unitaire < 10 ^e centile et < 70 % de la médiane (même code SH, même origine), sur au moins 3 déclarations	(médiane × quantité – valeur CIF) × (droits + 19 % × (1 + droits))
B3	cycle de 3 ou 4 sociétés dans le graphe des factures (liens ≥ 50 000 DT) passant par un maillon suspect (≥ 2 mois de TVA non déposée, ou CA déclaré < la moitié des factures émises)	TVA des factures du circuit
B4	encaissements + CA TTC > 1,5 et encaissements > 50 000 DT	(encaissements + 1,2 – CA TTC) × 19/119

■ Niveau C — contexte (jamais suffisant seul)

Règle	Se déclenche si
C1	au moins 5 déclarations en douane de moins de 3 000 DT en 7 jours, chez le même fournisseur
C2	machine importée sans TVA (avantage fiscal) puis refacturée sous le même code SH — montant : min(revendu ; importé) × 19 %
C3	au moins 10 mois sur 12 en crédit de TVA, avec demandes de remboursement, dans un secteur normalement débiteur (hors exportatrices)
C4	même dirigeant ou même adresse qu'une société radiée, redressée ou défaillante (≥ 3 mois de TVA non déposée) ; ou société de moins de 18 mois avec plus de 500 000 DT de flux
C5	CA par salarié > 99 ^e centile du secteur, ou plus de 500 000 DT d'importations avec 0 ou 1 salarié

Chaque montant est calculé sur la dernière année où la règle se déclenche.

4. Montant en jeu de l'entreprise (sans double comptage)

Montant = Σ par famille du plus grand montant de la famille

Famille	Règles
Ventes cachées ou TVA non reversée	A1, A2, A5, B1, B3, B4
TVA à l'import	A3
Exportations	A4
Douane	B2
Avantages fiscaux	C2

Exemple Sahel Électro : max(A1 = 76 000 ; B1 = 486 400 ; B4) + A3 40 000 = 526 400 DT. C1, C3, C4 et C5 n'ont pas de montant.

5. Catégorie (règles fixes)

- Contrôle recommandé : au moins 1 indice A avec plus de 20 000 DT en jeu, ou au moins 2 B, ou 1 B + 2 C.
- Données insuffisantes : une déclaration annuelle manque (sauf si déjà rouge : la preuve de tiers prime).
- Demande de justification : 1 B ou 2 C.
- Cohérent : sinon.
- Un indice A de 20 000 DT ou moins compte comme un B. Un seul indice C ne suffit jamais.

6. Force des indices

Force = $1 - (1 - p_1) \times (1 - p_2) \times \dots$ avec $p = 0,40$ (A), $0,25$ (B), $0,10$ (C)

- Zitouna Électro Maison (B2 + C4) : $1 - 0,75 \times 0,90 = 0,325$
- Sahel Électro (A1, A3, B1, B4, C3, C4) : $1 - 0,6^2 \times 0,75^2 \times 0,9^2 = 0,836$

7. Score (0 à 100)

Score = $100 \times (0,45 \times \text{probabilité IA} + 0,40 \times \text{force des indices} + 0,15 \times \text{atypicité})$

- Probabilité IA — LightGBM entraîné sur 580 contrôles passés (redressement = 1, sinon 0), environ 30 variables (« excès » comme $\max(0; TEJ \div CA - 1)$, marge sur 36 mois en écarts-types du secteur, ancienneté, taille, secteur...). Contraintes monotones : un excès plus grand ne fait jamais baisser le risque. Calibration isotonique (validation croisée 5 plis) ; score hors échantillon pour les entreprises déjà contrôlées. Bornée entre 1 % et 90 % (≈ 10 % des fraudeurs contrôlés ressortent sans redressement).
- Atypicité — Isolation Forest par secteur, sur 10 indicateurs neutralisés. r = rang dans le secteur (0 à 1) ; atypicité = $\max(0; 2r - 1)$: 0 pour la moitié la plus normale du secteur.
- Cascade SHAP — score = niveau moyen + 45 × (probabilité – moyenne), réparti entre variables selon SHAP + 40 × (force – moyenne), réparti selon $-\ln(1 - p) + 15 \times (\text{atypicité} - \text{moyenne})$.
- Exemple Zitouna : $0,45 \times 90 + 0,40 \times 32,5 + 0,15 \times 81 = 65,6$.

8. Priorité (ordre de la liste de ciblage)

Priorité = probabilité × montant en jeu

- Sahel Électro : $0,90 \times 526\,400 \approx 473\,760 \rightarrow 1^{\text{re}}$
- Zitouna Électro Maison : $0,90 \times 475\,702 \approx 428\,132 \rightarrow 2^{\text{e}}$

9. Dossier de contrôle — exemple Sahel Électro (2025)

Poste	Calcul	Montant
Coût des ventes net	$3\,000\,000 + 0 - 200\,000$	2 800 000 DT
CA reconstitué	$2\,800\,000 \times (1 + 20 \%)$	3 360 000 DT
Écart de CA	$3\,360\,000 - 800\,000$	2 560 000 DT
TVA sur ventes omises	$2\,560\,000 \times 19 \%$	486 400 DT
TVA déduite en trop	$610\,000 - 570\,000$	40 000 DT
Total TVA estimée	$486\,400 + 40\,000$	526 400 DT
IS (indicatif)	$2\,560\,000 \times 20 \% \times 15 \%$	76 800 DT
Pénalités (indicatives)	Σ sur 12 mois de $(TVA \div 12 \times 1,25 \% \times \text{mois de retard})$	$\approx 88\,800$ DT

Mois de retard : « par mois ou fraction de mois » (article 81 du CDPF), chaque mois étant dû le 28 du mois suivant. Estimation indicative, à confirmer par la procédure contradictoire. Le LLM ne calcule rien : il recopie ces montants ; une rédaction contenant un autre montant est rejetée au profit d'un modèle déterministe.

10. Mesure de la performance (vérité cachée, jamais utilisée pour entraîner)

Précision (top N) = fraudeurs réels parmi les N premiers ÷ N

- Top 100 : 100 %, contre 11 % au hasard ($\times 9,1$).
- Rappel (top N) = fraudeurs dans le top N ÷ 220 fraudeurs.
- Montant détecté (top N) = Σ montants réellement éludés par les fraudeurs du top N. Top 100 : 67,0 M DT (règles + IA) contre 41,2 M DT (règles seules), +63 %.
- Fausses alertes sur les pièges = pièges classés rouge ou orange ÷ 340 pièges : 1,5 % pour l'outil, contre 72 % pour la règle naïve « importations > CA local ».

11. Facilitation (T4)

- Fiable = aucun indice sur 3 ans + déclarations annuelles complètes + TVA à temps (au moins 24 mois, au plus 1 retard) + score < 10 + ancienneté ≥ 5 ans + aucun redressement + CA $\geq 500\,000$ DT.
- Candidate OEA = fiable, importatrice ou exportatrice, pas encore agréée.
- Remboursement rapide de TVA = fiable et exportatrice.

12. Assistant réglementaire (T9) — pour le contribuable ET pour l'agent

	Mode contribuable — Amel, gérante de PME	Mode agent — Sami, vérificateur
Besoin	comprendre ses droits et obligations	trouver l'article exact en préparant un contrôle
Style	langage simple, étapes concrètes, délais, pièces	technique : article, alinéa, conditions, exceptions, renvois
Exemple	« Le fisc me demande la liste de mes clients, en combien de temps ? » → article 16 : trente jours	« Durée maximale d'une vérification approfondie ? » → article 40 : 6 mois (1 an si comptabilité non conforme)
Autres	pénalité si je paie en retard (art. 81) ; le contrôleur peut-il venir sans prévenir ; conditions OEA	banques et relevés (art. 17) ; taxation d'office (art. 47) ; tarif de transaction (arrêté du 8 janvier 2002)

Même moteur de recherche, même garde-fous : seule la consigne de rédaction change. Le dossier de contrôle (T3) utilise aussi ce moteur pour citer les articles 16, 17, 40, 47, 81.

Les formules de l'assistant

Proximité = cosinus(question, extrait) = produit scalaire des vecteurs bge-m3 normalisés (1 024 dimensions)

Fusion RRF : score(extrait) = Σ poids ÷ (60 + rang dans chaque liste)

- Listes : sens (bge-m3 + FAISS) et mots-clés (BM25), pour la question et sa reformulation en français juridique (poids 1), plus l'expansion par le lexique juridique (poids 0,5). « Article N » cité → mis en tête directement.
- Test au démarrage : cosinus moyen sur 20 extraits $\geq 0,98$ (mesuré : 1,0).
- 8 meilleurs extraits transmis au modèle local (Qwen3 8B) ; lignes de tarif douanier exclues sauf question sur les équipements.
- Abstention si le meilleur cosinus $< 0,517$ — calibré sur 20 questions : $0,483$ (plus haute question hors sujet) + $(0,587$ (plus basse question couverte) – $0,483) \div 3$.
- Garde-fous : chaque citation [n] doit correspondre à un extrait fourni (sinon retirée) ; chaque délai, taux ou montant doit figurer dans les extraits (sinon affiché « à vérifier ») ; TVA et IRPP/IS signalés non couverts ; Code des douanes signalé en édition 2016.

En une phrase : on corrige les écarts honnêtes, on croise des sources indépendantes avec 14 règles, on classe avec deux modèles de machine learning expliqués par SHAP, et l'agent décide.